图书推荐系统：三人分工与分阶段实施方案（精简版）

1. 项目目标与数据概况

1.1 项目目标

基于用户—图书交互记录，为每位测试用户推荐其可能感兴趣的图书。项目以赛题说明中的 F1 为主要评价指标；当前提交样例显示每位用户对应 10 条推荐，因此本方案暂以“每位用户推荐 10 本不同且未交互过的图书”为实验目标。

推荐系统的核心流程为：

1. 检查并理解数据，确认训练、验证和提交数据格式。
2. 建立统一、可复现的离线验证集与评价代码。
3. 从简单热门度基线开始，逐步实现协同过滤和隐式反馈模型。
4. 在相同切分和指标下比较模型，分析用户活跃度与图书热门度带来的差异。
5. 选择验证表现稳定、结果格式正确的方案生成提交文件。

1.2 数据概况

文件	结构	观察结果
`data/train_dataset.csv`	`user_id,item_id`	5,869,631 条交互；53,424 位用户；10,000 本图书
`data/test_dataset.csv`	`user_id`	53,424 行；当前所有测试用户都在训练集中出现
`data/submission.csv`	`user_id,item_id`	每位用户 10 行，但示例中同一用户的 10 行都是图书 `5672`

其他初步观察：

- 用户交互量中位数约为 109 条，最少 17 条、最多 198 条。
- 图书交互量差异明显：中位数约为 241 条，最高约 22,714 条。
- 用户—图书交互矩阵约有 5.34 亿个可能组合，实际交互密度约为 **1.10%**，属于稀疏数据。
- 目录中暂未发现交互时间、评分、书名、作者或类别等字段。因此目前应以隐式反馈和协同过滤为主，不能假设可直接利用时间趋势或图书内容特征。
- 训练集检查未发现重复的用户—图书交互对。

> **重要：** 进入建模前，成员 A 应通过正式脚本再次生成统计报告，确保数据没有变化，并把统计脚本和运行命令纳入项目交付。

1.3 初步基线（参考）

采用固定随机种子 42，在每位用户的交互中随机留出约 20% 作为验证目标，用其余约 80% 统计图书热度；按热度从高到低，为每位用户推荐 10 本未出现在该用户训练部分中的图书。一次初步计算结果为：

指标	初步结果
Precision@10（micro）	约 0.1009
Recall@10（micro）	约 0.0459
F1@10（micro）	约 0.0631

这只是单次随机切分上的参考值，并非赛题最终成绩，也不应直接视作性能保证。正式基线应由成员 A 的脚本重新计算，并固定切分文件、随机种子、指标定义和代码版本。之后所有模型必须在同一验证集上进行比较。

2. 三人分工（三条线）

为避免职责重叠，建议将工作拆为“数据与评估”“协同过滤与挖掘”“潜因子与集成提交”三条线。三人共同遵守统一的数据切分和实验记录约定。

成员 A：数据分析、数据切分、评估与 BPR 模型

主要职责

1. 检查字段、空值、重复交互、用户和图书 ID 范围。
2. 生成数据统计：用户活跃度、图书热度、交互分布、稀疏度和长尾情况。
3. 建立固定的训练/验证切分，并保存或确定性重建切分。
4. 编写统一的 Top-K 推荐评估程序。
5. 实现并复核热门度 Top-10 基线。
6. 维护实验记录模板，汇总成员 B、C 的结果。
7. 检查测试用户覆盖率、推荐数量、重复图书、已读过滤与最终 CSV 格式。
8. 实现贝叶斯个性化排序（BPR）模型，作为对 ALS 的排序对照。

主要交付物

1. 数据概览统计结果和可复现脚本。
2. 固定的验证切分生成脚本或切分文件。
3. 统一评估脚本及指标说明。
4. 热门度 Top-10 基线代码和基线结果。
5. BPR 模型代码及验证结果。
6. 最终提交文件的自动化质量检查结果。

完成标准

- 同一代码、参数和随机种子可以重现相同切分与指标。
- 评估脚本能处理所有验证用户，且能发现缺少推荐、重复推荐和推荐已知图书等问题。
- 所有团队模型都能使用同一输入、输出约定接入评估。
- BPR 模型可在固定验证切分上运行并输出可比较的验证分数。

成员 B：协同过滤与图书共现挖掘

主要职责

1. 分析图书共现关系，识别热门书影响和长尾书表现。
2. 实现基于物品的协同过滤（ItemKNN）。
3. 对比不同相似度或热门度修正方法。
4. 控制邻居数量和中间数据规模，避免构造不必要的稠密矩阵。
5. 按统一评估脚本提交验证结果、配置和运行说明。

建议实验方向

- ItemKNN：对共同交互用户进行余弦相似度计算。
- 相似度加权：尝试对热门图书降权，避免热门书仅因用户多而主导相似度。
- 邻居截断：每本书仅保留 Top-N 相似图书，比较若干合理的 N。
- 候选打分：对用户历史交互图书的相似邻居分数进行累计，可比较是否按历史图书热度或相似度做权重。
- 对比无热门度修正和有热门度修正的结果。

主要交付物

1. 图书共现和热门度分析结果。
2. ItemKNN 推荐实现。
3. 参数配置、运行方式、验证分数和实验记录。
4. ItemKNN 对活跃用户、低活跃用户、热门图书和长尾图书的分层分析。

完成标准

- 推荐结果为每位用户生成 10 本互不重复的候选图书。
- 不推荐该用户在对应训练部分中已经交互过的图书。
- 相似度计算与候选生成可复现，能够在现有数据规模上运行。

成员 C：隐式反馈潜因子模型、融合与最终提交

主要职责

1. 实现并评估隐式反馈 ALS。
2. 针对潜因子维度、正则化、迭代轮数等进行有控制的调参。
3. 与成员 A、B 的基线及 ItemKNN 结果比较。
4. 评估简单模型融合是否带来稳定收益。
5. 负责最终使用完整训练数据拟合选定模型、对测试用户生成结果并输出提交 CSV。

建议实验方向

- 隐式反馈 ALS：将训练交互作为正反馈信号，学习用户和图书潜向量。
- 热门度融合：潜因子模型或 ItemKNN 分数与热门度分数进行简单加权；权重只在固定验证集上选择。
- 先使用少量有代表性的参数组合，不要在尚未确认指标与基线前进行大规模无计划搜索。

主要交付物

1. ALS 模型及验证结果。
2. 参数与训练说明、运行时间和资源需求。
3. 融合方案及其相对单模型的验证结果。
4. 最终推荐生成脚本、提交 CSV 和质量检查报告。

完成标准

- 最终训练仅使用可用的完整训练交互；验证调参结果与最终重训过程明确区分。
- 每位测试用户均生成规定数量的不同图书。
- 输出格式、用户集合、图书 ID 和已读过滤检查通过。

3. 分阶段实施计划

以下按 **两周左右的课程/竞赛项目节奏**安排。若实际周期不同，可按阶段和验收标准伸缩时间，不应跳过统一验证和最终提交检查。

阶段 1：项目启动与数据审计（第 1—2 天）

目标

- 让三位成员对任务、数据、输出格式和评价方法达成一致。
- 完成原始数据校验与关键统计输出。

负责人：成员 A 主责，全员查看关键统计。

工作内容

1. 阅读赛题说明及 CSV 文件，确认字段名、编码、样例内容。
2. 确认推荐数量：当前样例显示每位用户 10 行，暂定 Top-10。
3. 向教师或赛题方确认 F1 的计算方式：
    - 是对每位用户的 Top-10 计算后再取平均（macro），还是汇总所有用户的命中后计算（micro）？
    - 评估是否要求每位用户固定 10 个预测？
    - 预测能否包含训练中已交互过的书？通常应过滤，但应确认比赛规则。
    - 提交列名大小写是否严格要求 `user_id,item_id`？README 的文字说明与文件中的字段拼写存在大小写差异。
    - 赛题评测是否假定每位用户有固定数量的真实目标交互？
4. 校验训练集、测试集和提交样例的列名、数据类型、空值和 ID 范围。
5. 统计交互总数、唯一用户数、唯一图书数、重复用户—图书对。
6. 确认测试用户是否全部在训练用户集合中。
7. 检查提交样例每位用户的行数及是否存在重复推荐。
8. 约定代码目录、文件命名、实验记录格式和版本管理方式。

验收标准

- 形成书面评估口径；若暂时无法得到官方答复，则明确采用本方案的临时口径并在报告中披露。
- 三人能读取相同的原始数据，并知晓各自交付物。
- 统计结果可由脚本生成，不依赖手工复制。

阶段 2：切分方案与热门度基线（第 2—3 天）

目标

- 固定训练/验证切分与随机种子，确保三人使用完全一致的数据。
- 产出可复现的热门度 Top-10 基线与统一评估脚本。

负责人：成员 A 主责；成员 B、C 用该切分准备模型。

工作内容

1. 推荐首选按用户分层随机留出约 20% 交互作为验证目标，其余交互用于训练。
2. 固定随机种子（首轮可使用 42），切分应保证每位用户在训练部分仍有交互。
3. 保存切分索引或通过确定性脚本重建，确保三人使用完全一致的数据。
4. 对每位验证用户，从训练交互计算图书热度。
5. 按热度生成 Top-10，并过滤该用户训练部分已交互的图书。
6. 编写统一的 Precision@10、Recall@10、F1@10 计算程序。
7. 建议除主切分外，再用 1—2 个额外随机种子复测主要模型，避免只对单次切分过拟合。

指标定义

对每位用户 u，令推荐集合为 R_u，验证目标集合为 T_u，且 $|R_u|=10$：

- $P_u@10 = |R_u \cap T_u| / 10$
- $R_u@10 = |R_u \cap T_u| / |T_u|$
- $F1_u@10 = 2 \cdot P_u \cdot R_u / (P_u + R_u)$，当 $P_u+R_u=0$ 时记为 0

团队至少同时报告：

- **micro-F1@10**：先汇总所有用户的命中数、推荐数和目标数，再计算 Precision、Recall、F1。
- **macro-F1@10**：先计算每位用户的 F1@10，再对用户取平均。
- **micro Precision@10 和 micro Recall@10**：帮助判断 F1 变化来自精确率还是召回率。

若官方评分定义与以上不同，以官方规则为准，并重新计算所有模型。

验收标准

- 热门度基线结果可重现。
- 评估脚本通过人工构造的小型样例测试，例如全命中、零命中、部分命中和重复推荐。
- 形成团队统一的基线结果表。

阶段 3：并行建模（第 4—7 天）

目标

- 成员 B 完成 ItemKNN 实现与初步调参。
- 成员 C 完成隐式反馈 ALS 实现与初步调参。
- 各模型在固定验证切分上产出可比较的验证分数。

负责人：成员 B、C 并行；成员 A 支持评估与数据问题。

成员 B 工作

1. 先实现 ItemKNN 基础版。
2. 在固定验证切分上逐步尝试相似度、邻居数和热门度修正。
3. 记录每次变更，避免同时改多个因素而无法判断原因。
4. 分析模型对不同活跃度用户和长尾图书的效果。

成员 C 工作

1. 实现隐式反馈 ALS。
2. 先用小规模参数组合验证训练与推理流程，再扩大搜索。
3. 若 ALS 可稳定运行，再实现简单分数融合。
4. 确保训练过程不使用验证目标。

成员 A 工作

1. 维护验证切分、评估脚本和实验记录。
2. 核对各模型的推荐数、去重、已读过滤和运行时间。
3. 对必要的实验提供切分稳定性复测。

每个实验必须记入统一实验记录，包含：实验编号、负责人、数据切分、模型、关键参数、指标（micro/macro F1@10、Precision@10、Recall@10）、运行时间、备注。

验收标准

- 至少有一个可复现的 ItemKNN 结果和一个可复现的 ALS 结果。
- 各模型能在完全一致的验证目标上比较。
- 没有因用户 ID、图书 ID 映射不一致或数据切分不同导致的无效比较。

阶段 4：模型比较、误差分析与有限调参（第 8—10 天）

目标

- 以统一指标比较所有候选模型，选定最终模型与参数。
- 完成分层误差分析，确认模型优势与局限。

负责人：三人共同；成员 A 汇总，成员 B/C 各自解释模型结果。

工作内容

1. 以统一指标比较热门度、ItemKNN、ALS；若已实现，再加入融合。（BPR 由成员 A 负责）
2. 对主要模型复测额外随机种子，记录均值和波动。
3. 分层分析：
    - 低、中、高活跃用户的 F1@10。
    - 头部、中腰部、长尾图书的命中分布。
    - 推荐列表中热门图书占比及推荐多样性。
4. 检查模型是否只是重复推荐最热门图书，或对低活跃用户明显失效。
5. 对最有希望的模型做有限、有依据的调参；每次仅改变一类参数。
6. 仅在验证集有稳定收益时保留融合方案；简单加权融合可从验证分数归一化后开始。

模型选择建议

- 不能只根据一次切分上微小的分数提升决定最终模型。
- 若复杂模型与热门度基线相差不大，优先选择稳定、易复现、生成提交可靠的方案。
- 如果融合在多个随机切分上都优于单模型，再纳入最终候选。
- 报告中如实列出失败实验，不要只展示最高分结果。

验收标准

- 有一张包含所有候选模型及统一指标的比较表。
- 能解释最终候选模型为何优于基线，或为何保留更简单的基线。
- 实验结论在复测切分上没有明显反转；若有反转，应报告不稳定性。

阶段 5：最终训练、提交生成、复现与归档（第 11—14 天）

目标

- 使用完整训练数据重训最终模型，生成测试集推荐文件。
- 完成自动化质量检查，确保提交文件格式正确。
- 归档所有代码、实验记录与运行说明，确保可复现。

负责人：成员 C 主责；成员 A 做格式和质量验收；成员 B 检查推荐合理性。

工作内容

1. 根据阶段 4 的结果确定最终模型和参数。
2. 使用完整 `train_dataset.csv` 重新训练模型；不要把验证结果误当作最终训练模型结果。
3. 对 `test_dataset.csv` 中的每位用户生成 Top-10 推荐。
4. 过滤该用户完整训练记录中已经出现过的图书。
5. 若模型候选不足 10 本，按预先约定的回退策略补足，例如使用全局热门且用户未交互的图书。
6. 输出 CSV，文件名可为 `data/submission_final.csv`，不要覆盖原始样例。
7. 运行自动化质量检查并保存检查结果。

提交文件质量检查

- 列名与官方格式完全一致。
- 用户集合与测试文件完全一致，每位用户恰好 10 行。
- 每位用户的 10 本图书互不重复。
- 每个 `item_id` 都属于训练集中有效图书 ID 范围。
- 不包含用户在完整训练集中已经交互过的图书（如官方规则要求不过滤，则按官方规则执行并记录）。
- 没有空值，ID 数据类型正确，CSV 编码和分隔符符合要求。
- 提交文件不是原始 `submission.csv` 的重复图书占位结果。

归档与复现检查

- 整理数据统计、实验配置、验证结果、模型选择理由。
- 写清楚训练/验证切分、随机种子、指标计算口径和过滤规则。
- 保存从原始训练数据生成最终提交文件的完整运行命令。
- 检查其他成员能否按文档重新生成相同的验证结果和提交结构。
- 汇报数据挖掘发现、方法对比、局限性和后续改进方向。

最终交付物

1. 数据分析脚本与统计结果。
2. 固定切分生成器和统一评估脚本。
3. 热门度、ItemKNN、ALS（以及完成时的 BPR/融合）模型代码。
4. 实验记录与模型比较表。
5. 最终提交文件及质量检查报告。
6. 项目说明：运行方式、环境依赖、数据说明和已知限制。

4. 统一评估与建模规则

为了保证实验公平，三位成员共同遵守以下规则：

1. **不改变验证集。** 如需更换切分，必须同步更新所有模型并重新跑基线。
2. **验证目标不可泄漏。** 训练、相似度计算、热门度统计和参数拟合只能使用训练部分。
3. **统一推荐数量。** 暂按每位用户 10 本执行；若官方规则不同，以官方为准。
4. **统一已读过滤。** 对验证推荐过滤用户在验证训练部分已交互的图书；最终推荐过滤用户完整训练历史中已交互的图书。
5. **统一 ID 映射。** 模型内部重编号时必须保存映射，并在导出时还原原始 ID。
6. **统一回退方案。** 若模型未能产生 10 个候选，按未读热门图书补足，且记录发生次数。
7. **报告多项指标。** F1 为主，Precision、Recall、覆盖率和运行时间作为辅助。
8. **保留复现实验信息。** 每项结果要对应切分、代码版本、参数和随机种子。

5. 分析检查点

以下分析应贯穿相应阶段，作为模型评估的参考：

5.1 用户活跃度

把用户按训练交互数分层，例如按分位数分为低、中、高活跃组，观察：

- 热门度基线是否对低活跃用户更有效。
- ItemKNN 是否更适合交互较多的用户。
- ALS 是否能改善低活跃用户个性化程度。
- 不同分组的推荐列表长度、命中率和热门度构成。

分层边界应由实际分布确定，并在实验报告中说明，避免为了突出某模型而临时挑选分组。

5.2 图书热门度与长尾

按训练交互次数对图书排序并分组，分析：

- 头部图书贡献了多少交互。
- 基线 Top-10 的推荐结果是否集中在少量热门书。
- 不同模型分别覆盖了多少种图书。
- 长尾图书是否获得推荐，且是否带来验证命中。

可以报告推荐覆盖率（被推荐过的不同图书数 / 全部图书数）作为辅助指标，但不能用覆盖率替代 F1。

5.3 共现与相似度

对每对图书，统计共同交互用户数。原始共现容易偏向热门图书，因此可比较：

- 原始共现次数。
- 余弦相似度。
- 对热门度进行惩罚后的相似度。

对共现候选限制邻居数，优先保存每本书的高分邻居，避免生成规模过大的全量物品对矩阵。

5.4 冷启动情况

当前测试用户都在训练集中，说明用户冷启动不是首要问题。仍要确认：

- 是否有测试或验证会涉及训练中未出现的图书。
- 如果模型无法为某个用户生成足够候选，如何用未读热门图书补足。
- 所有模型对新图书是否采用一致处理策略。

6. 主要风险与应对

风险	影响	应对方式
官方 F1 口径与本地实现不同	离线高分不一定代表官方成绩	尽早确认 micro/macro、Top-K 和样本聚合规则；未确认时明确标注临时口径
验证切分与实际测试目标生成方式不同	离线排序可能不匹配线上评测	报告随机切分局限；若能获得官方划分说明，按官方方式调整验证
随机切分造成偶然波动	模型排名不稳定	固定主切分，并用额外种子复测主要候选
ItemKNN 共现计算过大	内存或运行时间超限	稀疏计算、逐批处理、限制每个物品保留的邻居数
ALS/BPR 调参耗时	挤占提交检查时间	先完成基线和 ItemKNN；设置调参截止点，优先交付可运行的完整方案

最终结果重复推荐或包含已读图书	提交无效或损失召回	在提交生成后运行用户级去重、历史过滤和行数检查
样例提交被误当作预测结果	所有用户获得相同图书，个性化失效	不覆盖原始样例；生成独立的 `submission_final.csv` 并做差异检查
缺少图书元数据	无法做内容型推荐和题材解释	先用隐式反馈方法；如后续获得合法可用的元数据，再作为独立扩展实验

7. 实验结果汇总表与项目目录

7.1 实验结果汇总表

每次阶段汇报至少更新以下表格：

模型	关键参数	切分/种子	micro-P@10	micro-R@10	micro-F1@10	macro-F1@10	覆盖率	备注
热门度 Top-10	无	固定主切分						基线
ItemKNN	相似度、邻居数	固定主切分						成员 B
隐式 ALS	因子数、正则化等	固定主切分						成员 C
BPR（可选）	采样与优化参数	固定主切分						成员 A
融合（可选）	模型与权重	固定主切分						仅保留稳定提升方案

对最终候选模型，再补充不同随机种子的结果和均值；不要把未使用相同切分的结果放在同一列直接排名。

7.2 推荐的项目目录组织

在不影响现有文件的前提下，可逐步整理为：

```
BookRecommendationSystem/
├── README.md
├── 项目分工与分阶段实施方案.md
├── data/
│   ├── train_dataset.csv
│   ├── test_dataset.csv
│   ├── submission.csv
│   └── submission_final.csv
├── src/
│   ├── data_analysis.py
│   ├── make_split.py
│   ├── evaluate.py
│   ├── popularity.py
│   ├── item_knn.py
│   ├── implicit_als.py
│   └── make_submission.py
└── reports/
    └── experiments.csv
```

此目录只是建议，不要求一次性创建所有文件。先实现可复现的评估和基线，再按实际代码结构调整，避免为了目录形式增加不必要工作。

8. 三人协作约定与项目完成判定

8.1 三人协作约定

- 共同维护一份实验记录；每次运行后及时登记参数与结果。
- 不直接覆盖原始数据或提交样例。
- 调整数据切分、评价口径、过滤规则时，先通知全员并同步重跑。
- 模型代码提供一致的输入输出接口：输入训练交互和用户列表，输出每用户有序的图书候选及分数。
- 结果比较以统一验证程序为准，不以训练损失或单个用户案例代替总体指标。
- 阶段 5 开始后冻结主要模型选择，除发现明确错误外，不再进行高风险的大规模重构。

8.2 项目完成判定

项目达到以下条件即可视为完成：

1. 数据统计和验证切分可复现。
2. 有热门度基线，且至少比较 ItemKNN 与隐式 ALS。
3. 主要结论使用统一切分、统一指标，至少对重点候选进行了稳定性复测。
4. 最终 CSV 对测试文件中的每位用户恰好输出 10 本不同图书（如官方要求不同则按官方要求），格式和 ID 校验通过。

5. 有完整的运行方式、实验记录和模型选择理由。
6. 报告中说明当前数据缺少时间及内容元数据的限制，并对未确认的官方评测细节明确标注假设。

— 文档结束 —